

MP 5134 · UT1

Què vol dir que un model aprèn?

Una introducció curta abans de tocar codi: què és l'aprenentatge automàtic, què és un model i què passa exactament quan l'entrenem.

Dues maneres de resoldre el mateix problema

Programació clàssica

Les regles les escrius tu

DADES + REGLES → RESPOSTES

Per endevinar el pes d'un pingüí hauries d'escriure tu les condicions: *si l'aleta fa més de 215 mm, llavors...*

Aprenentatge automàtic

Les regles les dedueix l'algorisme

DADES + RESPOSTES → REGLES

Li dones 342 pingüins ja mesurats i pesats, i el deixes trobar el patró tot sol.

D'aquí surt la conseqüència que marcarà tot el curs: **el model només serà tan bo com les dades que li donem.**

Una fórmula amb incògnites

```
massa = ? × aleta + ?
```

Un model acabat de crear **no sap res**. Té la forma — sap que la massa dependrà de l'aleta — però no sap amb quins números.

Aquestes incògnites són els **paràmetres** del model. També els trobaràs anomenats coeficients o pesos: són la mateixa cosa.

Provar valors i quedar-se amb el millor


SI EL COEFICIENT VAL...	ERROR MITJÀ (G)
10	575
20	478
30	394
40	337
50	312
60	335

Per a cada valor possible del coeficient podem mesurar **quant s'equivoca** el model sobre els 342 pingüins.

Aprendre és exactament això: **cercar els valors dels paràmetres que donen el millor rendiment**. Aquí, els que fan l'error més petit.

En aquest exemple només movem un coeficient. Amb tres, la cerca és la mateixa idea buscant tres valors alhora.

L'error dibuixa una vall



El fons de la vall el troba el model, no nosaltres. Cap algorisme prova els valors un per un com aquí — n'hi ha de molt més ràpids per baixar fins al fons — però la idea és aquesta.

Quatre números, i prou

```
massa = -6233,3 + 2,46 × llarg_bec + 13,15 × gruix_bec + 50,26 × llarg_aleta
```

Això és **tot** el que hi ha dins d'un model lineal entrenat. Entrenar ha consistit a trobar aquests quatre números.

Amb una calculadora i les mesures d'un pingüí obtindries exactament el mateix que et dona `predict()`

Sempre els mateixos tres passos

`fit(X, y)`

Cerca els paràmetres a partir dels exemples. És l'únic moment en què el model aprèn alguna cosa.

`predict(X)`

Aplica la fórmula trobada a mostres noves. Aquí ja no aprèn: només calcula.

`score(X, y)`

Mesura com de bé ho ha fet, sobre dades que no ha vist mai durant l'entrenament.

Canvia el model — una regressió, un arbre, una xarxa neuronal — i aquestes tres crides segueixen sent idèntiques. El que canvia és què s'amaga a dins de **`fit()`**.

Paràmetres i hiperparàmetres

Paràmetres

Els troba el model, dins de `fit()`

`coef_` `intercept_`

Són el resultat de l'entrenament. A scikit-learn acaben amb guió baix, i aquesta és la manera de reconèixer-los.

Hiperparàmetres

Els tries tu, **abans** d'entrenar

`max_depth=4` `test_size=0.2`

El model no els toca mai. Triar-los bé és un problema per si sol, i té una unitat sencera dedicada: la UT10.

Tres idees

- 1 Un model és una **fórmula amb números per determinar**.
- 2 Que un model **aprengui** vol dir que **cerca els valors d'aquests números que li donen el millor rendiment**.
- 3 Un resultat tot sol no vol dir res **fins que el compares amb una referència**.

La resta del que farem aquest curs és triar millors fórmules, millors dades i millors maneres de mesurar.