MP 5134 · UT2 · VERSIÓ CALIFORNIA HOUSING I DEMANDA ELÈCTRICA

# Regressió lineal i polinòmica

Abans d'obrir els notebooks: què farem en aquesta unitat, què és una regressió i quins són els tres models que construirem.

**Pere Prohens** · Politècnic Llevant · Curs 2026-27

ON SOM

# A la UT1 vam fer servir un model. Ara l'obrim.

### El que ja has fet

NB 1.2

Vas entrenar una **regressió lineal** amb tres mesures dels pingüins, en vas treure un R2 de 0,78 i vas veure que el model eren quatre números.

Però el vas fer servir com una capsa tancada: `fit()`, i ja està.

### El que farem ara

UT2 · 18 hores · 3 notebooks

Entendrem **què fa aquest model per dins**, com se'l llegeix, fins on arriba i què passa quan el forcem a fer més del que pot.

I aprendrem a respondre la pregunta important: **és bo, aquest model?**

# Predir un número

## Regressió

La resposta és una quantitat

```
massa del pingüí → 4.250 g
preu d'un habitatge → 180.000 $
vendes de la setmana → 312 u.
```

Pot sortir **qualsevol valor**, i l'error es mesura en les mateixes unitats: grams, dòlars, unitats venudes.

## Classificació

La resposta és una categoria · UT4

```
espècie del pingüí → Adelie
demà plourà? → sí
correu brossa? → no
```

La resposta és **una opció d'una llista tancada**, i només es pot encertar o fallar.

Tota la UT2 és regressió: sempre volem predir un número.

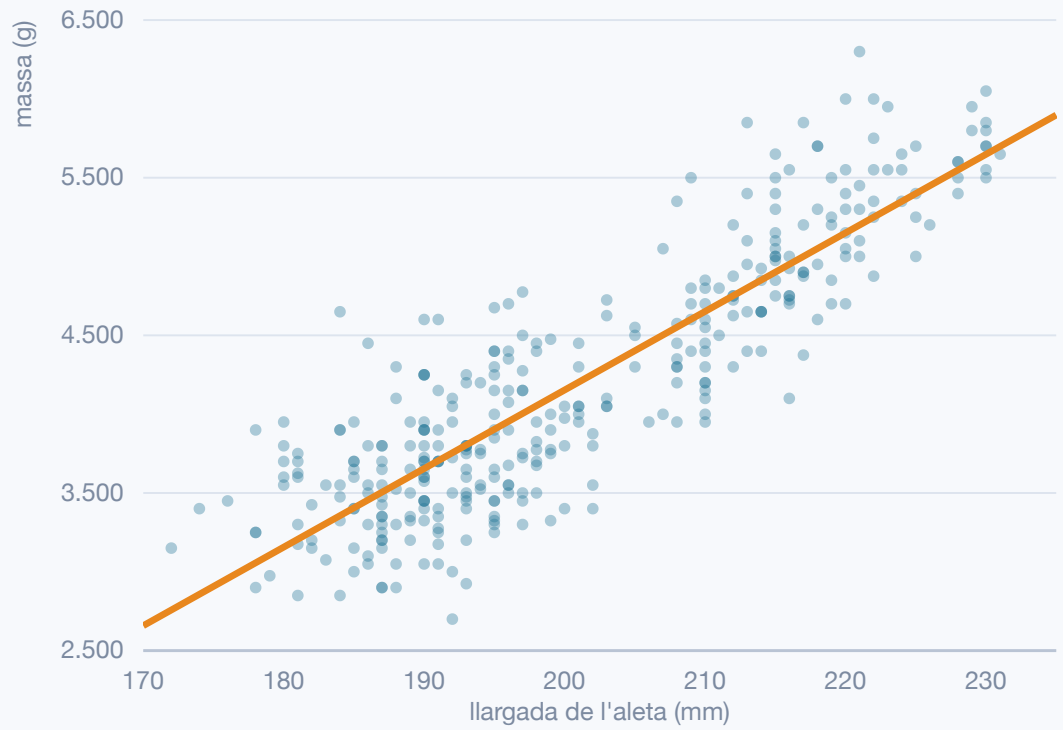
# Multiplicar cada entrada per un número, i sumar

$$\text{resposta} = ? \times \text{entrada}_1 + ? \times \text{entrada}_2 + \ldots + ?$$

Això és **tot** el que sap fer un model lineal. No sap fer arrels, ni condicions, ni corbes: només multiplicar i sumar.

Els interrogants són els **paràmetres** de la UT1, els números que el model busca a **fit()**. Els tres tipus de regressió que veurem fan servir aquesta mateixa fórmula. L'únic que canvia és **quines entrades li donem**.

# Regressió lineal simple: una entrada, una recta




```
massa = 49,85 × aleta − 5.817
```

Amb una sola entrada, la fórmula és una **recta**. Els dos paràmetres tenen nom:

**Pendent**: quant puja la recta per cada mil·límetre d'aleta.
**Ordenada a l'origen**: el valor de partida.

La recta es pot dibuixar i es pot llegir en veu alta: *cada mil·límetre d'aleta són uns 50 grams més de pingüí*.

# Regressió lineal múltiple: moltes entrades

```
preu = ? × ingressos + ? × latitud + ? × longitud + ? × edat + … + ?
```

La mateixa fórmula, però amb **un paràmetre per a cada variable**. Amb vuit variables, el model busca nou números.

Ja no és una recta i no es pot dibuixar. Per saber si funciona haurem de confiar en les **mètriques**.

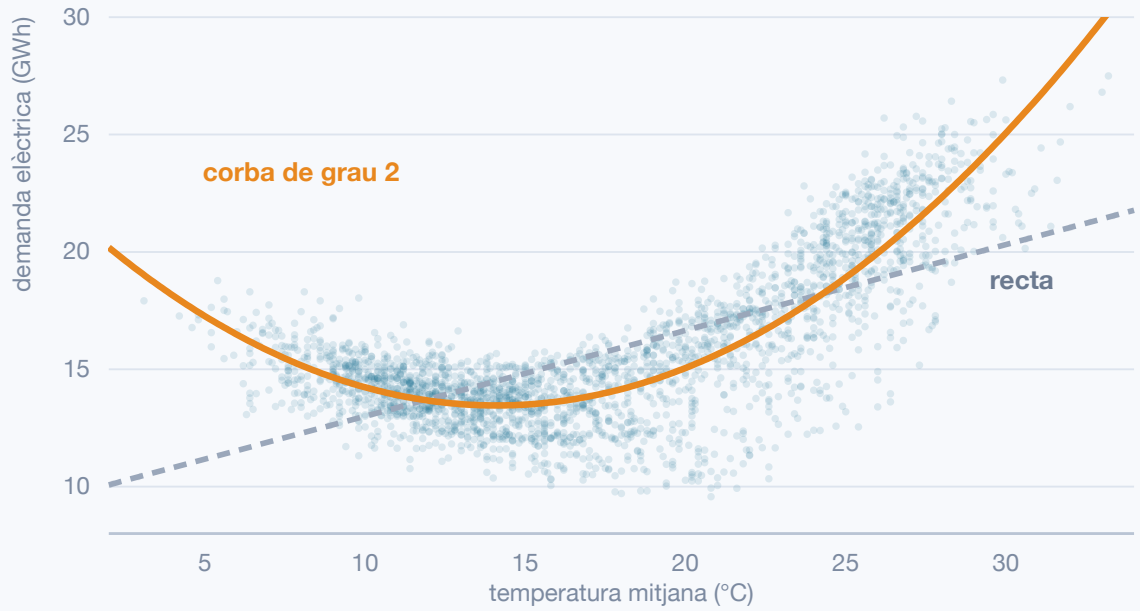
### La pregunta del NB 2.2

Dades noves: vint mil districtes de Califòrnia (cens de 1990)

Si li donem més variables, el model **prediu millor**? I quant millor? Les afegirem d'una en una i ho mesurarem.

Spoiler: la resposta no és la que sembla. Depèn de quanta **informació nova** porti cada variable.

# Regressió polinòmica: quan les dades fan corba




Les Balears gasten més electricitat quan fa fred i, sobretot, quan fa calor. Una recta no pot fer una U, i s'equivoca uns **2,1 GWh** al dia.

El truc: el model no es toca. El que fem és **fabricar entrades noves** a partir de la que tenim:

$$x \rightarrow x \quad x^2$$

Amb aquestes columnes, la mateixa suma dibuixa una corba i l'error baixa a **1,2 GWh**, gairebé la meitat. El nombre de columnes és el **grau**.

3 · ELS TRES TIPUS, JUNTS

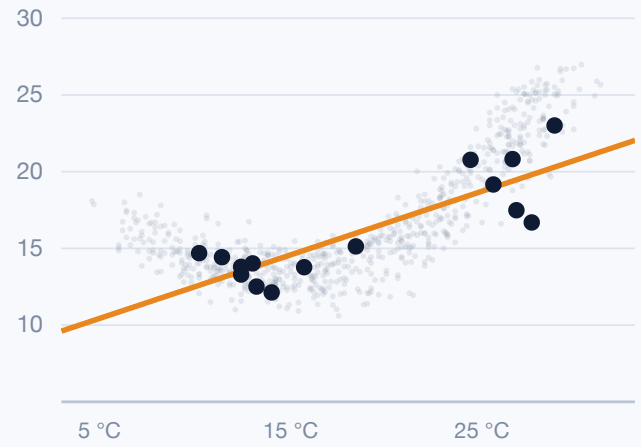
# Un sol model, tres maneres d'alimentar-lo

| TIPUS | ENTRADES | FORMA | EXEMPLE DE LA UT2 | A SCIKIT-LEARN |
|---|---|---|---|---|
| **Simple** | una variable | una recta | massa del pingüí a partir de l'aleta | `LinearRegression` |
| **Múltiple** | diverses variables | no es pot dibuixar | preu de l'habitatge a partir de les dades del districte | `LinearRegression` |
| **Polinòmica** | les variables, les seves potències i els seus productes | una corba | consum elèctric segons la temperatura; consum amb totes les variables combinades | `PolynomialFeatures` + `LinearRegression` |

Fixa't en l'última columna: **el model sempre és el mateix**. Totes tres són regressions lineals; el que canvia és la taula que li passem a **fit()**.

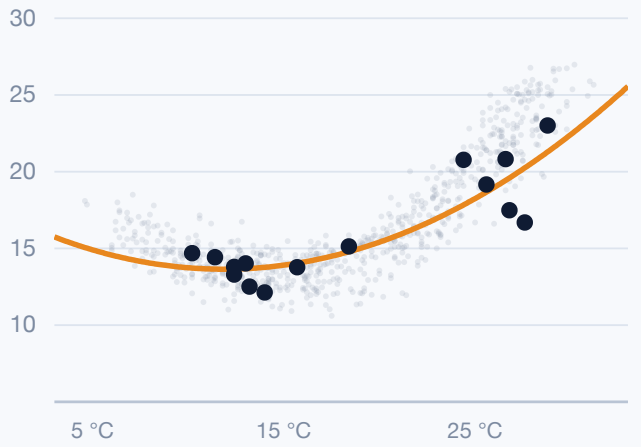
# Massa simple, just, massa complex

**Grau 1** INFRAAJUST



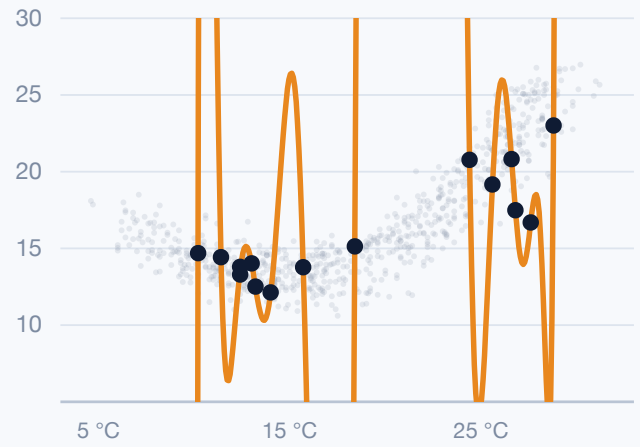

Error amb els 15 dies: **1,42 GWh**
Error amb dades noves: **2,1 GWh**

**Grau 2** RAONABLE




Error amb els 15 dies: **1,22 GWh**
Error amb dades noves: **1,5 GWh**

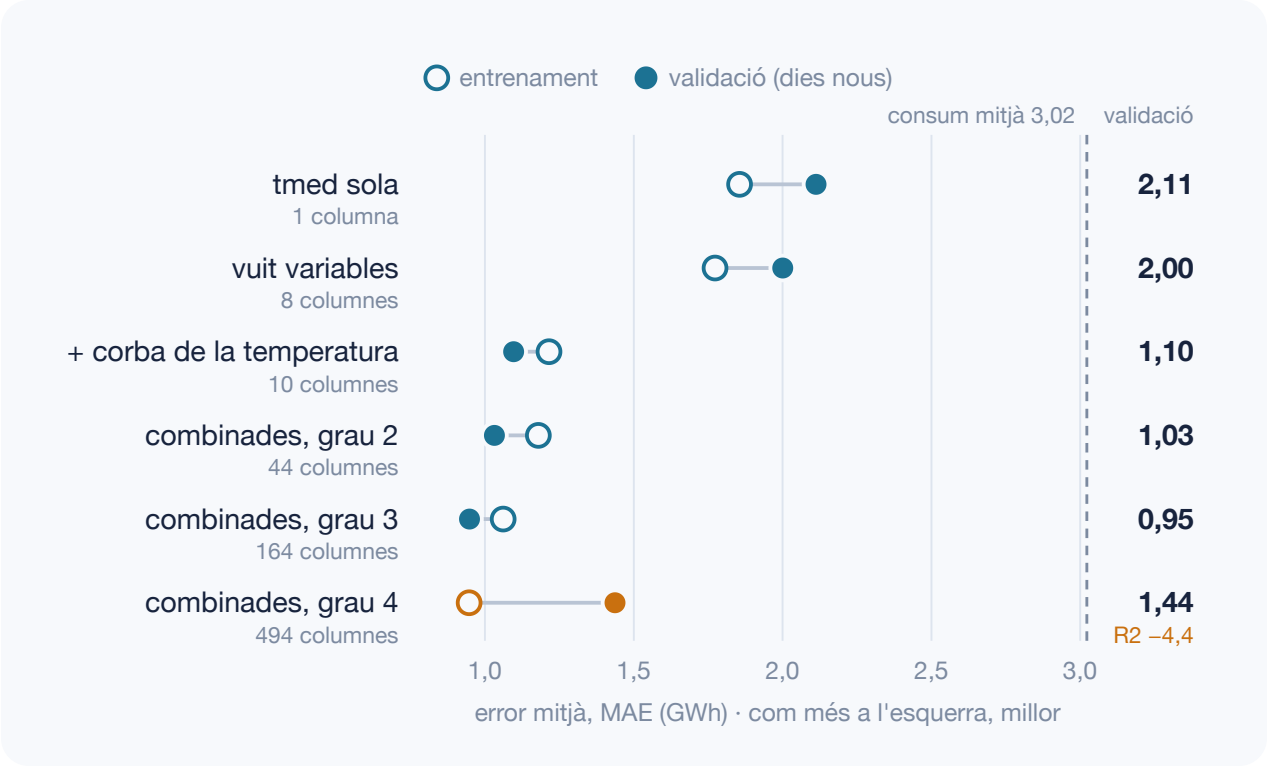
**Grau 15** SOBREAJUST




Error amb els 15 dies: **0,03 GWh**
Error amb dades noves: **42.576 GWh**

Els mateixos quinze dies de mesures, tres graus diferents. El grau 15 és el que **millor s'ajusta** a les dades d'entrenament i el que **pitjor prediu**: arriba a dir –33 milions de GWh els dies de fred. Això és el **sobreajust**, el problema central de tot l'aprenentatge automàtic.

# El consum elèctric, amb les eines noves




**Més variables en línia recta** gairebé no ajuden: amb vuit, l'error només baixa de 2,11 a 2,00 GWh.

**La corba de la temperatura** sí: les mateixes vuit variables amb la U baixen l'error a **1,10 GWh**.

**Combinar variables**: **PolynomialFeatures** també les multiplica entre elles. Amb grau 3 surten 164 columnes i l'error baixa a 0,95 GWh.

**Massa columnes**: amb grau 4, l'entrenament millora i la validació **empitjora**. Uns quants dies amb errors enormes enfonsen el R2 fins a –4,4.

Més entrades ajuden si el model les pot aprofitar. I si la validació s'allunya de l'entrenament, salta l'alarma.

5 · COM SABREM SI ÉS BO

# Quatre mètriques, quatre preguntes

### MAE

GRAMS, DÒLARS...

De mitjana, **quant m'equivoco**?

### RMSE

GRAMS, DÒLARS...

Quant m'equivoco, **castigant més els errors grans**?

### Desviació %

PERCENTATGE

De mitjana, **en quin percentatge** m'equivoco?

### R2

SENSE UNITATS

Quina part de l'error de **dir sempre la mitjana** m'he estalviat?

I sempre comparant amb una **referència**. Un error de 51.000 $ no diu res tot sol. El que el fa bo és que dir el preu mitjà de la zona, com faria qualsevol agent immobiliari, s'equivoca 78.000 $.

6 · UNA DECISIÓ PER A TOT EL CURS

# Les dades, en tres trossos




**Validació**: aquí comparem models i decidim quin és millor. Ho farem desenes de vegades.

**Test segellat**: es reserva al NB 2.2 i **no s'obre fins a la UT10**. Ens dirà, al final, com funcionen de veritat els models.

Amb els districtes de Califòrnia, els trossos es fan a l'atzar. Amb la demanda elèctrica del NB 2.3 tallarem per dates (2015–2021, 2022–2023 i, sota clau, 2024–2025), perquè allà volem predir dies que encara no han arribat.

PER ENDUR-SE'N

# Abans d'obrir el NB 2.1

1. Una **regressió** prediu un número.
2. Un model **lineal** només multiplica cada entrada per un número i ho suma tot. Simple, múltiple i polinòmica són **el mateix model amb entrades diferents**.
3. Un model que encerta les dades d'entrenament **no és per força un bon model**. El que compta és com prediu dades que no ha vist mai.
4. Més entrades ajuden **si porten informació nova**. Massa entrades, i el model memoritza.