MP 5134 · UT1 I UT2 · CURS 2026-27

Conceptes clau

Entorn de treball, primer model i regressió lineal i polinòmica

COM FER-LA SERVIR

Aquesta llista recull els conceptes que han sortit a la UT1 i a la UT2. Tenla a mà quan estudiïs i quan facis els exercicis.

Si no saps explicar un concepte amb les teves paraules, torna al notebook que s'hi indica.

LLEGENDA

En negreta	Conceptes principals de les dues unitats.
Sense negreta	Conceptes que han sortit de passada.
NB 2.1	On l'has vist: notebook o diapositives.
→ UT3	Unitat on es tornarà a treballar a fons.

1 Fonaments

Aprenentatge automàtic	L'algorisme dedueix les regles a partir d'exemples (dades + respostes → regles), en lloc d'escriure-les nosaltres. El model només és tan bo com les dades que li donem. NB 1.1 · diapos UT1
Model	Una fórmula amb incògnites. Acabat de crear en té la forma, però no els números. diapos UT1
Entrenar (aprendre)	Buscar els valors dels paràmetres que fan l'error més petit: el fons de la «vall» de l'error. diapos UT1 · NB 2.1
Paràmetres (pesos o coeficients)	Els números que el model troba sol dins de `fit()`. A scikit-learn acaben amb guió baix: `coef_`, `intercept_`. NB 1.2
Hiperparàmetres	La configuració que triem nosaltres abans d'entrenar i que el model no toca mai: `max_depth`, `test_size`, el grau del polinomi. NB 1.2 · NB 2.3 → UT7
Regressió i classificació	La regressió prediu un número; la classificació, una categoria d'un conjunt tancat. NB 1.1 · diapos UT2 → UT4

VIST DE PASSADA

Aprenentatge supervisat	Aprendre d'exemples dels quals ja coneixem la resposta. NB 1.1
Predir no és endevinar el futur	És omplir un buit amb informació que no tenim, com la massa d'un pingüí que no hem pesat. NB 1.1

2 Les dades

Mostra, característica i variable objectiu	Una fila, una columna d'entrada (*feature*) i la columna que volem predir (*target*). L'objectiu no pot ser mai una entrada. NB 1.1
X i y	`X` és la taula d'entrades: dues dimensions, en majúscula i amb doble claudàtor encara que tingui una sola columna. `y` és el vector objectiu. NB 1.2 · NB 2.1
Valors absents	La majoria d'estimadors de scikit-learn no els accepten. Tres sortides: eliminar les files (`dropna`), eliminar la columna o imputar. NB 1.1 → UT3
Mirar les dades abans de modelar	`shape`, `head`, `info`, `describe`, `value_counts` i `isna`, abans d'entrenar res. NB 1.1 · NB 2.2
Histograma i mapa de dispersió	L'histograma mostra la forma d'una distribució; el mapa de dispersió enfronta dues variables. NB 1.1 · NB 2.1 · NB 2.2

VIST DE PASSADA

Colab i dades per URL	`read_csv` accepta una URL, i així tothom treballa amb el mateix fitxer. NB 1.1

Tipus de columna	`float64`, `int64` i `object`. Una columna numèrica que surt com a `object` amaga text. NB 1.1
Llegir un `describe()`	Recompte, mínims i màxims raonables, mitjana contra mediana, quartils. NB 1.1
DataFrame i Series	Selecció amb `[[...]]` i `[...]`, filtres de cert o fals, `.loc` i `groupby`. NB 1.1 · NB 2.2
Variables categòriques	Cap model accepta text, i numerar-les 0, 1, 2 inventa un ordre que no existeix. La solució és el one-hot. NB 1.1 · NB 2.2 → **UT3**
Imputació	Omplir els buits amb la mitjana, la mediana o un valor estimat. NB 1.1 → **UT3**
Desbalanç de classes	Classes amb proporcions molt diferents, com les tres espècies de pingüins. NB 1.1 → **UT4**
Correlació que canvia de signe	Mirant tots els pingüins junts, els becs llargs són prims; dins de cada espècie, són gruixuts. NB 1.1 → **UT3**
Soroll	El gruix del núvol de punts: un error que cap model pot eliminar amb les entrades que té. NB 2.1 · NB 2.2
Valors atípics i errors de dades	Una sola dada mal apuntada dispara el RMSE. Els casos reals difícils no es treuen per maquillar les mètriques. NB 2.1
Dades tallades	Els preus topats a 500.001 $: el model no veu mai cap preu més alt. NB 2.2
Categories amb molt poques mostres	`ISLAND`, amb quatre districtes, dona estimacions poc fiables. NB 2.2
Gràfica amb color	`scatter` amb `c=` i `colorbar` per afegir-hi una tercera variable. NB 2.2

3 Treballar amb scikit-learn

L'estimador és un objecte	Cada model és una classe. `LinearRegression()` crea un objecte que encara no sap res. NB 1.2
`fit`, `predict` i `score`	Aprendre (canvia l'estat intern de l'objecte), predir mostres noves i puntuar. La mateixa interfície serveix per a tots els models. NB 1.2 · diapos UT1
Transformadors: `fit`, `transform` i `fit_transform`	`fit` prepara l'eina mirant les dades; `transform` les converteix. Es preparen només amb l'entrenament i després es reapliquen a la validació i al test. NB 2.3 → **UT3 · UT9**
`random_state`	Fixa l'atzar perquè la partició i el resultat es puguin reproduir. Al NB 2.2 és «el pany del segell». NB 1.2 · NB 2.2

VIST DE PASSADA

Altres estimadors, la mateixa interfície	`DecisionTreeClassifier`, `DecisionTreeRegressor`, `RandomForestRegressor`, `SVC`: canviar de model és canviar una línia. NB 1.2 → **UT5 · UT6**
Arbre de decisió	El classificador d'espècies del NB 1.2, amb `max_depth=4`. NB 1.2 → **UT5**

4 Avaluar honestament

Entrenament i prova (`train_test_split`)	Apartar dades abans d'entrenar, amb un test d'entre el 10% i el 30%. Avaluar amb dades vistes és corregir un examen a qui ha vist les respostes. NB 1.2 → **UT7**
Conjunt de validació	Un tros per comparar models i triar hiperparàmetres sense tocar el test (60/20/20). NB 2.2 · NB 2.3 → **UT7**
Test segellat	Es reserva al principi i s'obre una sola vegada, a la UT10. Cada decisió presa mirant la validació la fa una mica optimista. NB 2.2 · NB 2.3 → **UT10**
Model de referència (`DummyRegressor`, `DummyClassifier`)	Un model que no mira les dades: diu sempre la mitjana o la classe més freqüent. Un número tot sol no vol dir res fins que el compares. NB 1.2 · NB 2.1 · NB 2.2

Fuga d'informació (*data leakage*)	El model veu informació que no tindria en predir: l'objectiu entre les entrades, o un transformador preparat amb dades de validació. NB 1.2 · NB 2.3 → **UT7 · UT9**

VIST DE PASSADA

Referència de sentit comú	El que diria un expert sense aprenentatge automàtic, com el preu mitjà de la zona. També és un model, i es calcula només amb l'entrenament. NB 2.2
Mirar casos concrets	Una taula real / predit / error ensenya el que la mitjana amaga. NB 1.2 · NB 2.1
Variabilitat de la mesura	Amb un test petit, canviar la llavor mou el R2. «El model no necessita més dades, la mesura sí.» NB 1.2 → **UT7**
Partició a l'atzar o per dates	A l'atzar quan les mostres són independents, com al cens; per dates quan volem predir dies que encara no han arribat. NB 2.2 · NB 2.3
Mostres veïnes que s'assemblen	Amb una partició a l'atzar, un districte de prova sovint té el veí a l'entrenament, i el resultat surt optimista. NB 2.2 → **UT7**
Validació creuada	La versió sòlida de partir les dades en entrenament i validació. NB 1.2 · NB 2.2 → **UT7**

5 Regressió lineal i polinòmica

Regressió lineal	Multiplicar cada entrada per un número i sumar-ho tot. No sap fer corbes ni condicions. diapos UT2
Regressió lineal simple	Una entrada i una recta, definida pel pendent (quant puja per cada unitat) i l'ordenada a l'origen (el punt de partida). NB 2.1
Regressió lineal múltiple	Diverses entrades, amb un coeficient per a cada variable. Ja no es pot dibuixar. NB 2.2
Llegir els coeficients	«Per cada mil·límetre d'aleta, uns 50 grams més.» Amb diverses variables s'hi afegeix «si la resta no canvien», i no es poden comparar entre si. NB 1.2 · NB 2.1 · NB 2.2
Afegir variables	Només ajuda si aporta informació nova que el model pugui aprofitar. Té costos: cal tenir-les totes per predir, el model s'explica pitjor i sobreajusta més fàcilment. NB 2.2 · NB 2.3
Extrapolació	Predir fora del rang de les dades d'entrenament, on el model continua la recta i diu bestieses. NB 2.1 · NB 2.2
Regressió polinòmica (`PolynomialFeatures`)	Fabricar columnes noves (x^2, x^3…) perquè el mateix model lineal dibuixi corbes. El grau és un hiperparàmetre. NB 2.3

VIST DE PASSADA

Què minimitza `fit()`	Els errors al quadrat, no el MAE. Per això la seva recta no és idèntica a la que trobem provant pendents a mà. NB 2.1
Ordenada sense sentit físic	Un pingüí d'aleta zero pesaria −6 kg: és un ajust matemàtic, no una afirmació sobre pingüins. NB 1.2 · NB 2.1 · NB 2.2
Variables redundants	Quatre mides del districte que diuen el mateix es reparteixen el pes i donen coeficients absurds. NB 2.2 → **UT3**
Variables que només funcionen juntes	La latitud i la longitud: soles diuen poc; juntes diuen on és el districte. NB 2.2
Interaccions	Amb diverses entrades, `PolynomialFeatures` també les multiplica entre elles (`tmax × cap_de_setmana`). NB 2.3
Fabricar variables a mà	Donar al model la informació ja preparada, com la distància a la ciutat més propera. NB 2.2 · NB 2.3 → **UT3**
Escalat	Dividir la temperatura entre 30 perquè les potències no es disparin, i posar les variables a la mateixa escala per poder comparar coeficients. NB 1.2 · NB 2.2 · NB 2.3 → **UT3**
Interpretabilitat	La regressió lineal «s'explica sola»; els models més potents, no. NB 2.1 → **UT5**

Importància de variables	Com mesurar quina variable pesa més de veritat. NB 2.2 → **UT5**

6 Mètriques de regressió

MAE	De mitjana, quant m'equivoco, en les unitats de la variable. Es pot explicar a qualsevol. NB 2.1
RMSE	Eleva els errors al quadrat abans de fer la mitjana i castiga els grans. Sempre surt igual o més gran que el MAE. NB 2.1
Desviació percentual (MAPE)	L'error mitjà en percentatge, sense unitats. Es torna boja quan els valors reals són propers a zero. NB 2.1
R2	La part de l'error de «dir sempre la mitjana» que ens estalviem. 1 és perfecte, 0 és com dir la mitjana i un valor negatiu és pitjor. És el que dona `score()` en regressió. NB 1.2 · NB 2.1
Triar la mètrica segons el problema	El MAE si tots els errors costen igual; el RMSE si un error gran és molt pitjor que molts de petits (el veterinari). Mirar-ne sempre més d'una. NB 2.1 · NB 2.3

VIST DE PASSADA

Error d'una predicció	Predit menys real. El signe diu si el model es passa o es queda curt. NB 2.1
Quocient RMSE / MAE	Cap a 1,2 o 1,3 és normal; 1,5 o més avisa d'uns quants errors enormes. NB 2.1
MAE estable i R2 enfonsat	Pocs errors catastròfics gairebé no mouen el MAE, però enfonsen el R2. NB 2.3
Accuracy	El percentatge d'encerts, que és el que dona `score()` en classificació. NB 1.2 → **UT4**

7 Sobreajust

Infraajust (*underfitting*)	El model és massa simple per a la forma de les dades i s'equivoca molt fins i tot amb l'entrenament. NB 2.3
Sobreajust (*overfitting*)	El model memoritza l'entrenament, soroll inclòs, i falla amb dades noves. NB 2.3
Error d'entrenament contra error de validació	La distància entre tots dos és el senyal d'alarma. L'error d'entrenament sempre prefereix el model més complex, i per això no serveix per triar. NB 2.2 · NB 2.3
Complexitat del model i quantitat de dades	El sobreajust depèn de la relació entre totes dues. Es combat simplificant el model o aconseguint més dades. NB 2.3

VIST DE PASSADA

On comença el sobreajust	Als llocs on hi ha poques dades, com els extrems de temperatura. NB 2.3
El mateix dilema en altres models	La profunditat de l'arbre, la `C` de les SVM i la cerca d'hiperparàmetres. NB 2.3 → **UT5 · UT6 · UT7**