MP 5134 · UT1 I UT2 · CURS 2026-27

# Conceptes clau

Entorn de treball, primer model i regressió lineal i polinòmica

**COM FER-LA SERVIR**

Aquesta llista recull els conceptes que han sortit a la UT1 i a la UT2. Tenla a mà quan estudiïs i quan facis els exercicis.

Marca la casella d'un concepte quan el sàpigues explicar amb les teves paraules. Si no te'n surts, torna al notebook que s'hi indica.

**LLEGENDA**

| | |
|---|---|
| **En negreta** | Conceptes principals de les dues unitats. |
| Sense negreta | Conceptes que han sortit de passada. |
| NB 2.1 | On l'has vist: notebook o diapositives. |
| → UT3 | Unitat on es tornarà a treballar a fons. |

## 1 Fonaments

| | |
|---|---|
| ☐ **Aprenentatge automàtic** | L'algorisme dedueix les regles a partir d'exemples (dades + respostes → regles), en lloc d'escriure-les nosaltres. El model només és tan bo com les dades que li donem. NB 1.1 · diapos UT1 |
| ☐ **Model** | Una fórmula amb incògnites. Acabat de crear en té la forma, però no els números. diapos UT1 |
| ☐ **Entrenar (aprendre)** | Buscar els valors dels paràmetres que fan l'error més petit: el fons de la «vall» de l'error. diapos UT1 · NB 2.1 |
| ☐ **Paràmetres (pesos o coeficients)** | Els números que el model troba sol dins de `fit()`. A scikit-learn acaben amb guió baix: `coef_`, `intercept_`. NB 1.2 |
| ☐ **Hiperparàmetres** | La configuració que triem nosaltres abans d'entrenar i que el model no toca mai: `max_depth`, `test_size`, el grau del polinomi. NB 1.2 · NB 2.3 → **UT7** |
| ☐ **Regressió i classificació** | La regressió prediu un número; la classificació, una categoria d'un conjunt tancat. NB 1.1 · diapos UT2 → **UT4** |

**VIST DE PASSADA**

| | |
|---|---|
| ☐ Aprenentatge supervisat | Aprendre d'exemples dels quals ja coneixem la resposta. NB 1.1 |
| ☐ Predir no és endevinar el futur | És omplir un buit amb informació que no tenim, com la massa d'un pingüí que no hem pesat. NB 1.1 |

## 2 Les dades

| | |
|---|---|
| ☐ **Mostra, característica i variable objectiu** | Una fila, una columna d'entrada (*feature*) i la columna que volem predir (*target*). L'objectiu no pot ser mai una entrada. NB 1.1 |
| ☐ **X i y** | `X` és la taula d'entrades: dues dimensions, en majúscula i amb doble claudàtor encara que tingui una sola columna. `y` és el vector objectiu. NB 1.2 · NB 2.1 |
| ☐ **Valors absents** | La majoria d'estimadors de scikit-learn no els accepten. Tres sortides: eliminar les files (`dropna`), eliminar la columna o imputar. NB 1.1 → **UT3** |
| ☐ **Mirar les dades abans de modelar** | `shape`, `head`, `info`, `describe`, `value_counts` i `isna`, abans d'entrenar res. NB 1.1 · NB 2.2 |
| ☐ **Histograma i mapa de dispersió** | L'histograma mostra la forma d'una distribució; el mapa de dispersió enfronta dues variables. NB 1.1 · NB 2.1 · NB 2.2 |

VIST DE PASSADA

| | |
|---|---|
| ☐ Colab i dades per URL | `read_csv` accepta una URL, i així tothom treballa amb el mateix fitxer. NB 1.1 |
| ☐ Tipus de columna | `float64`, `int64` i `object`. Una columna numèrica que surt com a `object` amaga text. NB 1.1 |
| ☐ Llegir un `describe()` | Recompte, mínims i màxims raonables, mitjana contra mediana, quartils. NB 1.1 |
| ☐ DataFrame i Series | Selecció amb `[[...]]` i `[...]`, filtres de cert o fals, `.loc` i `groupby`. NB 1.1 · NB 2.2 |
| ☐ Variables categòriques | Cap model accepta text, i numerar-les 0, 1, 2 inventa un ordre que no existeix. La solució és el one-hot. NB 1.1 · NB 2.2 → **UT3** |
| ☐ Imputació | Omplir els buits amb la mitjana, la mediana o un valor estimat. NB 1.1 → **UT3** |
| ☐ Desbalanç de classes | Classes amb proporcions molt diferents, com les tres espècies de pingüins. NB 1.1 → **UT4** |
| ☐ Correlació que canvia de signe | Mirant tots els pingüins junts, els becs llargs són prims; dins de cada espècie, són gruixuts. NB 1.1 → **UT3** |
| ☐ Soroll | El gruix del núvol de punts: un error que cap model pot eliminar amb les entrades que té. NB 2.1 · NB 2.2 |
| ☐ Valors atípics i errors de dades | Una sola dada mal apuntada dispara el RMSE. Els casos reals difícils no es treuen per maquillar les mètriques. NB 2.1 |
| ☐ Dades tallades | Els preus topats a 500.001 $: el model no veu mai cap preu més alt. NB 2.2 |
| ☐ Categories amb molt poques mostres | `ISLAND`, amb quatre districtes, dona estimacions poc fiables. NB 2.2 |
| ☐ Gràfica amb color | `scatter` amb `c=` i `colorbar` per afegir-hi una tercera variable. NB 2.2 |

# 3 Treballar amb scikit-learn

| | |
|---|---|
| ☐ **L'estimador és un objecte** | Cada model és una classe. `LinearRegression()` crea un objecte que encara no sap res. NB 1.2 |
| ☐ **`fit`, `predict` i `score`** | Aprendre (canvia l'estat intern de l'objecte), predir mostres noves i puntuar. La mateixa interfície serveix per a tots els models. NB 1.2 · diapos UT1 |
| ☐ **Transformadors: `fit`, `transform` i `fit_transform`** | `fit` prepara l'eina mirant les dades; `transform` les converteix. Es preparen només amb l'entrenament i després es reapliquen a la validació i al test. NB 2.3 → **UT3 · UT9** |
| ☐ **`random_state`** | Fixa l'atzar perquè la partició i el resultat es puguin reproduir. Al NB 2.2 és «el pany del segell». NB 1.2 · NB 2.2 |

VIST DE PASSADA

| | |
|---|---|
| ☐ Altres estimadors, la mateixa interfície | `DecisionTreeClassifier`, `DecisionTreeRegressor`, `RandomForestRegressor`, `SVC`: canviar de model és canviar una línia. NB 1.2 → **UT5 · UT6** |
| ☐ Arbre de decisió | El classificador d'espècies del NB 1.2, amb `max_depth=4`. NB 1.2 → **UT5** |

# 4 Avaluar honestament

| | |
|---|---|
| ☐ **Entrenament i prova (`train_test_split`)** | Apartar dades abans d'entrenar, amb un test d'entre el 10% i el 30%. Avaluar amb dades vistes és corregir un examen a qui ha vist les respostes. NB 1.2 → **UT7** |
| ☐ **Conjunt de validació** | Un tros per comparar models i triar hiperparàmetres sense tocar el test (60/20/20). NB 2.2 · NB 2.3 → **UT7** |
| ☐ **Test segellat** | Es reserva al principi i s'obre una sola vegada, a la UT10. Cada decisió presa mirant la validació la fa una mica optimista. NB 2.2 · NB 2.3 → **UT10** |

| | |
|---|---|
| ☐ **Model de referència (`DummyRegressor`, `DummyClassifier`)** | Un model que no mira les dades: diu sempre la mitjana o la classe més freqüent. Un número tot sol no vol dir res fins que el compares. NB 1.2 · NB 2.1 · NB 2.2 |
| ☐ **Fuga d'informació (*data leakage*)** | El model veu informació que no tindria en predir: l'objectiu entre les entrades, o un transformador preparat amb dades de validació. NB 1.2 · NB 2.3 → **UT7 · UT9** |

VIST DE PASSADA

| | |
|---|---|
| ☐ Referència de sentit comú | El que diria un expert sense aprenentatge automàtic, com el preu mitjà de la zona. També és un model, i es calcula només amb l'entrenament. NB 2.2 |
| ☐ Mirar casos concrets | Una taula real / predit / error ensenya el que la mitjana amaga. NB 1.2 · NB 2.1 |
| ☐ Variabilitat de la mesura | Amb un test petit, canviar la llavor mou el R2. «El model no necessita més dades, la mesura sí.» NB 1.2 → **UT7** |
| ☐ Partició a l'atzar o per dates | A l'atzar quan les mostres són independents, com al cens; per dates quan volem predir dies que encara no han arribat. NB 2.2 · NB 2.3 |
| ☐ Mostres veïnes que s'assemblen | Amb una partició a l'atzar, un districte de prova sovint té el veí a l'entrenament, i el resultat surt optimista. NB 2.2 → **UT7** |
| ☐ Validació creuada | La versió sòlida de partir les dades en entrenament i validació. NB 1.2 · NB 2.2 → **UT7** |

## 5 Regressió lineal i polinòmica

| | |
|---|---|
| ☐ **Regressió lineal** | Multiplicar cada entrada per un número i sumar-ho tot. No sap fer corbes ni condicions. diapos UT2 |
| ☐ **Regressió lineal simple** | Una entrada i una recta, definida pel pendent (quant puja per cada unitat) i l'ordenada a l'origen (el punt de partida). NB 2.1 |
| ☐ **Regressió lineal múltiple** | Diverses entrades, amb un coeficient per a cada variable. Ja no es pot dibuixar. NB 2.2 |
| ☐ **Llegir els coeficients** | «Per cada mil·límetre d'aleta, uns 50 grams més.» Amb diverses variables s'hi afegeix «si la resta no canvien», i no es poden comparar entre si. NB 1.2 · NB 2.1 · NB 2.2 |
| ☐ **Afegir variables** | Només ajuda si aporta informació nova que el model pugui aprofitar. Té costos: cal tenir-les totes per predir, el model s'explica pitjor i sobreajusta més fàcilment. NB 2.2 · NB 2.3 |
| ☐ **Extrapolació** | Predir fora del rang de les dades d'entrenament, on el model continua la recta i diu bestieses. NB 2.1 · NB 2.2 |
| ☐ **Regressió polinòmica (`PolynomialFeatures`)** | Fabricar columnes noves ($x^2$, $x^3$…) perquè el mateix model lineal dibuixi corbes. El grau és un hiperparàmetre. NB 2.3 |

VIST DE PASSADA

| | |
|---|---|
| ☐ Què minimitza `fit()` | Els errors al quadrat, no el MAE. Per això la seva recta no és idèntica a la que trobem provant pendents a mà. NB 2.1 |
| ☐ Ordenada sense sentit físic | Un pingüí d'aleta zero pesaria −6 kg: és un ajust matemàtic, no una afirmació sobre pingüins. NB 1.2 · NB 2.1 · NB 2.2 |
| ☐ Variables redundants | Quatre mides del districte que diuen el mateix es reparteixen el pes i donen coeficients absurds. NB 2.2 → **UT3** |
| ☐ Variables que només funcionen juntes | La latitud i la longitud: soles diuen poc; juntes diuen on és el districte. NB 2.2 |
| ☐ Interaccions | Amb diverses entrades, `PolynomialFeatures` també les multiplica entre elles (`tmax × cap_de_setmana`). NB 2.3 |

| | | |
|---|---|---|
| ☐ | Fabricar variables a mà | Donar al model la informació ja preparada, com la distància a la ciutat més propera. NB 2.2 · NB 2.3 → **UT3** |
| ☐ | Escalat | Dividir la temperatura entre 30 perquè les potències no es disparin, i posar les variables a la mateixa escala per poder comparar coeficients. NB 1.2 · NB 2.2 · NB 2.3 → **UT3** |
| ☐ | Interpretabilitat | La regressió lineal «s'explica sola»; els models més potents, no. NB 2.1 → **UT5** |
| ☐ | Importància de variables | Com mesurar quina variable pesa més de veritat. NB 2.2 → **UT5** |

## 6 Mètriques de regressió

| | | |
|---|---|---|
| ☐ | **MAE** | De mitjana, quant m'equivoco, en les unitats de la variable. Es pot explicar a qualsevol. NB 2.1 |
| ☐ | **RMSE** | Eleva els errors al quadrat abans de fer la mitjana i castiga els grans. Sempre surt igual o més gran que el MAE. NB 2.1 |
| ☐ | **Desviació percentual (MAPE)** | L'error mitjà en percentatge, sense unitats. Es torna boja quan els valors reals són propers a zero. NB 2.1 |
| ☐ | **R2** | La part de l'error de «dir sempre la mitjana» que ens estalviem. 1 és perfecte, 0 és com dir la mitjana i un valor negatiu és pitjor. És el que dona `score()` en regressió. NB 1.2 · NB 2.1 |
| ☐ | **Triar la mètrica segons el problema** | El MAE si tots els errors costen igual; el RMSE si un error gran és molt pitjor que molts de petits (el veterinari). Mirar-ne sempre més d'una. NB 2.1 · NB 2.3 |

VIST DE PASSADA

| | | |
|---|---|---|
| ☐ | Error d'una predicció | Predit menys real. El signe diu si el model es passa o es queda curt. NB 2.1 |
| ☐ | Quocient RMSE / MAE | Cap a 1,2 o 1,3 és normal; 1,5 o més avisa d'uns quants errors enormes. NB 2.1 |
| ☐ | MAE estable i R2 enfonsat | Pocs errors catastròfics gairebé no mouen el MAE, però enfonsen el R2. NB 2.3 |
| ☐ | Accuracy | El percentatge d'encerts, que és el que dona `score()` en classificació. NB 1.2 → **UT4** |

## 7 Sobreajust

| | | |
|---|---|---|
| ☐ | **Infraajust (*underfitting*)** | El model és massa simple per a la forma de les dades i s'equivoca molt fins i tot amb l'entrenament. NB 2.3 |
| ☐ | **Sobreajust (*overfitting*)** | El model memoritza l'entrenament, soroll inclòs, i falla amb dades noves. NB 2.3 |
| ☐ | **Error d'entrenament contra error de validació** | La distància entre tots dos és el senyal d'alarma. L'error d'entrenament sempre prefereix el model més complex, i per això no serveix per triar. NB 2.2 · NB 2.3 |
| ☐ | **Complexitat del model i quantitat de dades** | El sobreajust depèn de la relació entre totes dues. Es combat simplificant el model o aconseguint més dades. NB 2.3 |

VIST DE PASSADA

| | | |
|---|---|---|
| ☐ | On comença el sobreajust | Als llocs on hi ha poques dades, com els extrems de temperatura. NB 2.3 |
| ☐ | El mateix dilema en altres models | La profunditat de l'arbre, la `C` de les SVM i la cerca d'hiperparàmetres. NB 2.3 → **UT5 · UT6 · UT7** |