

MP 5134 · UT2

Regressió lineal i polinòmica

Abans d'obrir els notebooks: què farem en aquesta unitat, què és una regressió i quins són els tres models que construirem.

A la UT1 vam fer servir un model. Ara l'obrim.

El que ja has fet

NB 1.2

Vas entrenar una **regressió lineal** amb tres mesures dels pingüins, en vas treure un R^2 de 0,78 i vas veure que el model eren quatre números.

Però el vas fer servir com una capsula tancada: `fit()`, i ja està.

El que farem ara

UT2 · 18 hores · 3 notebooks

Entendrem **què fa aquest model per dins**, com se'l llegeix, fins on arriba i què passa quan el forcem a fer més del que pot.

I aprendrem a respondre la pregunta important: **és bo, aquest model?**

Predir un número

Regressió

La resposta és una quantitat

massa del pingüí → 4.250 g

màxima de demà → 27,4 °C

vendes de la setmana → 312 u.

Pot sortir **qualsevol valor**, i l'error es mesura en les mateixes unitats: grams, graus, unitats venudes.

Classificació

La resposta és una categoria · UT4

espècie del pingüí → Adelie

demà plourà? → sí

correu brossa? → no

La resposta és **una opció d'una llista tancada**, i només es pot encertar o fallar.

Tota la UT2 és regressió: sempre volem predir un número.


Multiplicar cada entrada per un número, i sumar

$$\text{resposta} = ? \times \text{entrada}_1 + ? \times \text{entrada}_2 + \dots + ?$$

Això és **tot** el que sap fer un model lineal. No sap fer arrels, ni condicions, ni corbes: només multiplicar i sumar.

Els interrogants són els **paràmetres** de la UT1, els números que el model busca a **fit()**. Els tres tipus de regressió que veurem fan servir aquesta mateixa fórmula. L'únic que canvia és **quines entrades li donem**.

Regressió lineal simple: una entrada, una recta



$$\text{massa} = 49,85 \times \text{aleta} - 5.817$$

Amb una sola entrada, la fórmula és una **recta**. Els dos paràmetres tenen nom:

Pendent: quant puja la recta per cada mil·límetre d'aleta.

Ordenada a l'origen: el valor de partida.

La recta es pot dibuixar i es pot llegir en veu alta: *cada mil·límetre d'aleta són uns 50 grams més de pingüí.*

Regressió lineal múltiple: moltes entrades

```
tmax_demà = ? × tmax + ? × tmin + ? × sol + ? × pressió + ... + ?
```

La mateixa fórmula, però amb **un paràmetre per a cada variable**. Amb deu variables, el model busca onze números.

Ja no és una recta i no es pot dibuixar. Per saber si funciona haurem de confiar en les **mètriques**.


La pregunta del NB 2.2

Dades noves: onze anys de temps a Palma, dia a dia (AEMET)

Si li donem més variables, el model **prediu millor**? I quant millor? Les afegirem d'una en una i ho mesurarem.

Spoiler: la resposta no és la que sembla. Depèn de quanta **informació nova** porti cada variable.

Regressió polinòmica: quan les dades fan corba



La temperatura puja i baixa al llarg de l'any. Una recta no pot fer una muntanya, i s'equivoca uns **5,2 °C**.

El truc: el model no es toca. El que fem és **fabricar entrades noves** a partir de la que tenim:

$$x \rightarrow x \quad x^2 \quad x^3 \quad x^4$$


Amb aquestes columnes, la mateixa suma dibuixa una corba i l'error baixa a **2,0 °C**. El nombre de columnes és el **grau**.

Un sol model, tres maneres d'alimentar-lo

TIPUS	ENTRADES	FORMA	EXEMPLE DE LA UT2	A SCIKIT-LEARN
Simple	una variable	una recta	massa del pingüí a partir de l'aleta	<code>LinearRegression</code>
Múltiple	diverses variables	no es pot dibuixar	màxima de demà a partir del temps d'avui	<code>LinearRegression</code>
Polinòmica	les variables, les seves potències i els seus productes	una corba	temperatura segons el dia de l'any; màxima de demà amb les variables combinades	<code>PolynomialFeatures</code> + <code>LinearRegression</code>


Fixa't en l'última columna: **el model sempre és el mateix**. Totes tres són regressions lineals; el que canvia és la taula que li passem a `fit()`.

Massa simple, just, massa complex



Els mateixos quinze dies de mesures, tres graus diferents. El grau 15 és el que **millor s'ajusta** a les dades d'entrenament i el que **pitjor prediu**: arriba a dir -51 °C a l'abril. Això és el **sobreajust**, el problema central de tot l'aprenentatge automàtic.

La màxima de demà, amb les eines noves



La corba de l'any diu al model en quin punt de l'onada som. L'error baixa de 1,54 a **1,46 °C**: més que totes les variables del NB 2.2 juntes.

Combinar variables: amb diverses columnes, **PolynomialFeatures** també les multiplica entre elles. Amb grau 2 surten 65 columnes i l'error baixa a 1,48 °C.

Massa columnes: amb grau 3, l'entrenament millora i la validació **empitjora**. Sobreajust, amb 2.500 dies de dades.

Més entrades ajuden si porten informació nova. I la distància entre els dos punts és el senyal d'alarma.

Quatre mètriques, quatre preguntes

MAE

GRAMS, GRAUS...

De mitjana, **quant**
m'equivoco?

RMSE

GRAMS, GRAUS...

Quant m'equivoco, **castigant**
més els errors grans?

Desviació %

PERCENTATGE

De mitjana, **en quin**
percentatge m'equivoco?

R2

SENSE UNITATS

Quina part de l'error de **dir**
sempre la mitjana m'he
estalviat?

I sempre comparant amb una **referència**. Un error de 1,6 °C sembla molt bo, fins que descobreixes que dir *demà farà com avui* ja s'equivoca això mateix.

Les dades de l'AEMET, en tres trossos

Entrenament

2015–2021 · el model hi aprèn amb fit()

Validació

2022–2023

Test segellat

2024–2025

Validació: aquí comparem models i decidim quin és millor. Ho farem desenes de vegades.

Test segellat: es reserva al NB 2.2 i **no s'obre fins a la UT10**. Ens dirà, al final, com funcionen de veritat els models.

Per què no triar els dies a l'atzar, com a la UT1? Perquè volem predir el futur: el model aprèn del passat i s'avalua amb anys que encara no ha vist.

Abans d'obrir el NB 2.1

- 1 Una **regressió** prediu un número.
- 2 Un model **lineal** només multiplica cada entrada per un número i ho suma tot. Simple, múltiple i polinòmica són **el mateix model amb entrades diferents**.
- 3 Un model que encerta les dades d'entrenament **no és per força un bon model**. El que compta és com prediu dades que no ha vist mai.
- 4 Més entrades ajuden **si porten informació nova**. Massa entrades, i el model memoritza.