

MP 5134 · UT2

Regressió lineal i polinòmica

Abans d'obrir els notebooks: què farem en aquesta unitat, què és una regressió i quins són els tres models que construirem.

A la UT1 vam fer servir un model. Ara l'obrim.

El que ja has fet

NB 1.2

Vas entrenar una **regressió lineal** amb tres mesures dels pingüins, en vas treure un R^2 de 0,78 i vas veure que el model eren quatre números.

Però el vas fer servir com una capsula tancada: `fit()`, i ja està.

El que farem ara

UT2 · 18 hores · 3 notebooks

Entendrem **què fa aquest model per dins**, com se'l llegeix, fins on arriba i què passa quan el forcem a fer més del que pot.

I aprendrem a respondre la pregunta important: **és bo, aquest model?**

Predir un número

Regressió

La resposta és una quantitat

massa del pingüí → 4.250 g

màxima de demà → 27,4 °C

vendes de la setmana → 312 u.

Pot sortir **qualsevol valor**, i l'error es mesura en les mateixes unitats: grams, graus, unitats venudes.

Classificació

La resposta és una categoria · UT4

espècie del pingüí → Adelie

demà plourà? → sí

correu brossa? → no

La resposta és **una opció d'una llista tancada**, i només es pot encertar o fallar.

Tota la UT2 és regressió: sempre volem predir un número.


Multiplicar cada entrada per un número, i sumar

$$\text{resposta} = ? \times \text{entrada}_1 + ? \times \text{entrada}_2 + \dots + ?$$

Això és **tot** el que sap fer un model lineal. No sap fer arrels, ni condicions, ni corbes: només multiplicar i sumar.

Els interrogants són els **paràmetres** de la UT1, els números que el model busca a **fit()**. Els tres tipus de regressió que veurem fan servir aquesta mateixa fórmula. L'únic que canvia és **quines entrades li donem**.

Regressió lineal simple: una entrada, una recta



$$\text{massa} = 49,85 \times \text{aleta} - 5.817$$

Amb una sola entrada, la fórmula és una **recta**. Els dos paràmetres tenen nom:

Pendent: quant puja la recta per cada mil·límetre d'aleta.

Ordenada a l'origen: el valor de partida.

La recta es pot dibuixar i es pot llegir en veu alta: *cada mil·límetre d'aleta són uns 50 grams més de pingüí.*

Regressió lineal múltiple: moltes entrades

$$tmax_demà = ? \times tmax + ? \times tmin + ? \times sol + ? \times pressió + \dots + ?$$

La mateixa fórmula, però amb **un paràmetre per a cada variable**. Amb deu variables, el model busca onze números.

Ja no és una recta i no es pot dibuixar. Per saber si funciona haurem de confiar en les **mètriques**.


La pregunta del NB 2.2

Dades noves: onze anys de temps a Palma, dia a dia (AEMET)

Si li donem més variables, el model **prediu millor**? I quant millor? Les afegirem d'una en una i ho mesurarem.

Spoiler: la resposta no és la que sembla.

Regressió polinòmica: quan les dades fan corba



La temperatura puja i baixa al llarg de l'any. Una recta no pot fer una muntanya, i s'equivoca uns **5,2 °C**.

El truc: el model no es toca. El que fem és **fabricar entrades noves** a partir de la que tenim:

$$x \rightarrow x \quad x^2 \quad x^3 \quad x^4$$


Amb aquestes columnes, la mateixa suma dibuixa una corba i l'error baixa a **2,0 °C**. El nombre de columnes és el **grau**.

Un sol model, tres maneres d'alimentar-lo

TIPUS	ENTRADES	FORMA	EXEMPLE DE LA UT2	A SCIKIT-LEARN
Simple	una variable	una recta	massa del pingüí a partir de l'aleta	<code>LinearRegression</code>
Múltiple	diverses variables	no es pot dibuixar	màxima de demà a partir del temps d'avui	<code>LinearRegression</code>
Polinòmica	una variable i les seves potències	una corba	temperatura segons el dia de l'any	<code>PolynomialFeatures</code> + <code>LinearRegression</code>

Fixa't en l'última columna: **el model sempre és el mateix**. Totes tres són regressions lineals; el que canvia és la taula que li passem a `fit()`.

Massa simple, just, massa complex



Els mateixos quinze dies de mesures, tres graus diferents. El grau 15 és el que **millor s'ajusta** a les dades d'entrenament i el que **pitjor prediu**: arriba a dir -51 °C a l'abril. Això és el **sobreajust**, el problema central de tot l'aprenentatge automàtic.

Quatre mètriques, quatre preguntes

MAE

GRAMS, GRAUS...

De mitjana, **quant**
m'equivoco?

RMSE

GRAMS, GRAUS...

Quant m'equivoco, **castigant**
més els errors grans?

Desviació %

PERCENTATGE

De mitjana, **en quin**
percentatge m'equivoco?

R2

SENSE UNITATS

Quina part de l'error de **dir**
sempre la mitjana m'he
estalviat?

I sempre comparant amb una **referència**. Un error de 1,6 °C sembla molt bo, fins que descobreixes que dir *demà farà com avui* ja s'equivoca això mateix.

Les dades de l'AEMET, en tres trossos

Entrenament

2015–2021 · el model hi aprèn amb fit()

Validació

2022–2023

Test segellat

2024–2025

Validació: aquí comparem models i decidim quin és millor. Ho farem desenes de vegades.

Test segellat: es reserva al NB 2.2 i **no s'obre fins a la UT10**. Ens dirà, al final, com funcionen de veritat els models.

Per què no triar els dies a l'atzar, com a la UT1? Perquè volem predir el futur: el model aprèn del passat i s'avalua amb anys que encara no ha vist.

Abans d'obrir el NB 2.1

- 1 Una **regressió** prediu un número.
- 2 Un model **lineal** només multiplica cada entrada per un número i ho suma tot. Simple, múltiple i polinòmica són **el mateix model amb entrades diferents**.
- 3 Un model que encerta les dades d'entrenament **no és per força un bon model**. El que compta és com prediu dades que no ha vist mai.