MP 5134 · UT3

Correlacions i preparació de variables

Abans d'obrir els notebooks: com es mira quines variables van juntes, i com es posen les dades en una forma que el model pugui fer servir.

Pere Prohens · Politècnic Llevant · Curs 2026-27

ON SOM

A la UT2 vam donar al model el que ja estava a punt

El que ja has fet

NB 2.2 · California Housing

Una regressió lineal amb les **vuit columnes numèriques** dels districtes. Error de validació: uns **51.200 $**.

La columna `ocean_proximity` es va quedar fora: és text, i el model només entén números.

El que farem ara

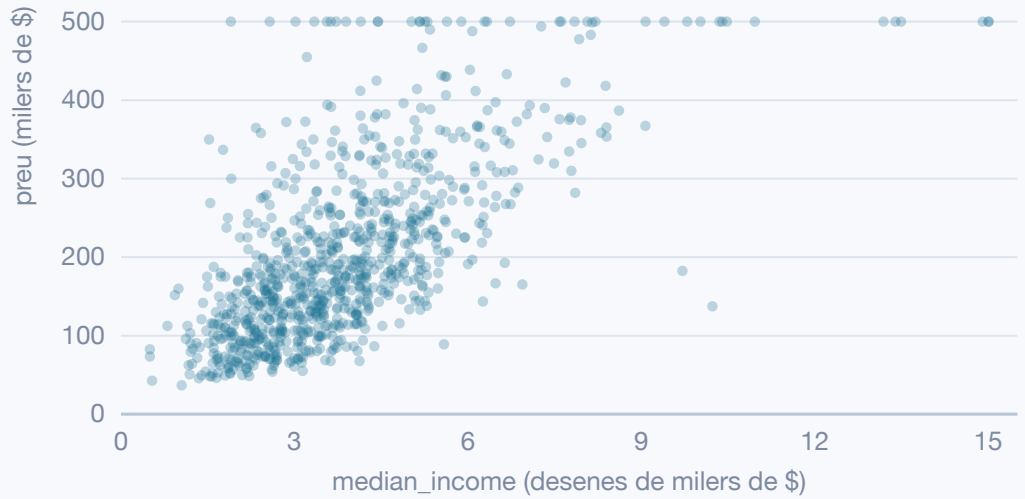
UT3 · 3 notebooks i una sessió de consolidació

Mirar abans d'entrenar: quines variables van juntes amb el preu, i quines van juntes entre elles (NB 3.1).

Preparar les variables: que no en quedi cap fora, i que les que hi entren ho facin en la millor forma possible (NB 3.2 i 3.3).

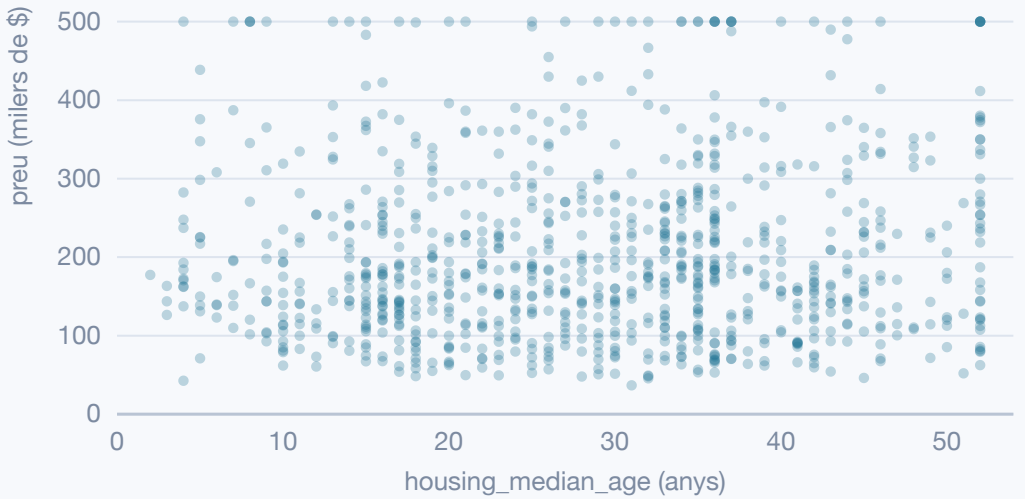
Un número que diu si dues variables van juntes

median_income CORRELACIÓ 0,69



Com més renda té el districte, més car és l'habitatge. Els punts fan **una franja que puja**.

housing_median_age CORRELACIÓ 0,10



L'edat de les cases gairebé no diu res del preu. Els punts fan **un núvol pla**.

Va de **–1** a **1**. El signe diu la direcció i la mida, la força: `~0 res` `0,3 feble` `0,7 forta` `1 perfecta`

El mapa de calor: totes les parelles d'un cop d'ull



Cada casella és la correlació d'una parella. **Blau**: pugen juntes. **Taronja**: una puja i l'altra baixa. Blanc: res.

La fila que ens interessa és la del **preu**. Ordenada: median_income **0,69** i, molt lluny, latitude –0,14 i total_rooms 0,13.

Compte: longitude hi surt amb **–0,05**, i sabem que la ubicació importa. La correlació **només mira rectes, i una variable cada vegada**. Un número baix no vol dir que la variable sigui inútil.

Quan dues columnes diuen el mateix

VARIABLE	VARIABLE	CORRELACIÓ
total_bedrooms	households	**0,98**
total_rooms	total_bedrooms	**0,93**
longitude	latitude	**–0,92**
total_rooms	households	**0,92**
population	households	**0,91**

Les parelles de la matriu que passen de **0,9**. Un districte amb el doble de llars té gairebé el doble de dormitoris, d'habitacions i de gent.

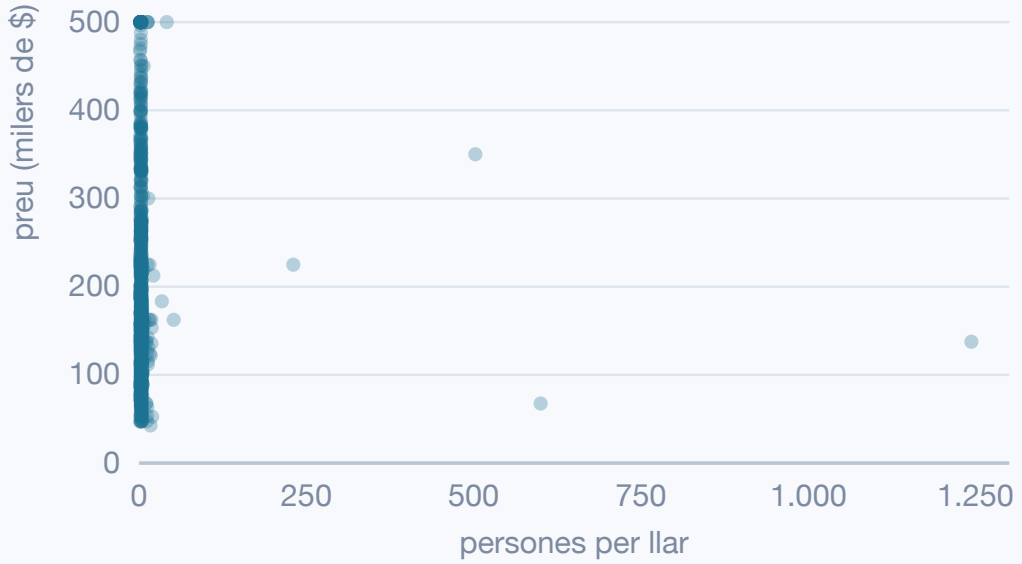
Quatre d'aquestes parelles mesuren el mateix: **la mida del districte**. Afegir-ne una altra no dona informació nova al model. (La cinquena és la forma de Califòrnia: la costa va en diagonal.)

Remei del NB 3.2: en lloc dels totals, fer servir **proporcions** (habitacions per llar, persones per llar), que ja no depenen de la mida.

Uns quants districtes estranys poden enganyar la correlació

Tots els districtes

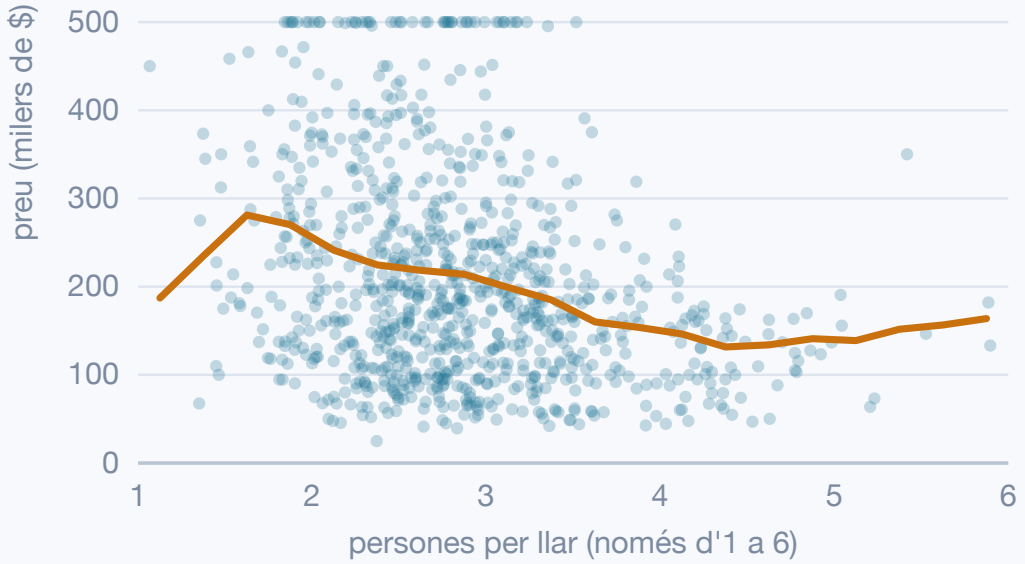
PEARSON −0,02



35 districtes tenen més de 10 persones per llar, i un arriba a **1.243** (residències, casernes…). Aixafen tota la resta contra l'esquerra.

Zoom d'1 a 6

PEARSON −0,28



Sense els extrems sí que hi ha relació: amb més gent per llar, l'habitatge és **més barat** (línia taronja: mitjana de cada tram).

Pearson busca una recta i els extrems l'arrosseguen. **Spearman** només mira l'ordre i amb totes les dades ja dona **−0,26**. Si no coincideixen, mira el gràfic.

Que vagin juntes no vol dir que l'una causi l'altra

Els dies que es venen més gelats hi ha més rescats a la platja.

A → B ?

Els gelats fan que la gent s'ofegui?
No.

B → A ?

Els rescats fan vendre gelats?
Tampoc.

C → A i B

La **calor** porta gent a la platja, i això fa pujar les dues coses. Una tercera variable les mou totes dues.

Per predir, una correlació així pot servir. Per **decidir què canviar** al món real, no. I a la consolidació de la UT3 hi ha una columna sospitosa: l'hauràs de trobar.

El model només vol números, complets i ben repartits

Text

ONEHOTENCODER · ORDINALENCODER

`INLAND` no és un número.

Cal **convertir les categories** en columnes numèriques.

Buits

SIMPLEIMPUTER

Si falta una dada, **fit()** s'atura. Es pot **omplir** amb la mediana, en lloc d'esborrar la fila.

Cues llargues

PROPORCIONS · LOGARITME

Columnes amb uns pocs valors enormes. Es **fabriquen variables noves** que el model aprofita millor.

Escales

STANDARDSCALER

Renda en desenes de milers, edat en anys… Es posen totes a **la mateixa escala**.

Cada problema té la seva eina a scikit-learn, i totes funcionen igual: són **fàbriques** que es preparen amb **fit()** i després transformen les taules amb **transform()**.

One-hot: una columna de 0 i 1 per a cada categoria

	<1H OCEAN	INLAND	NEAR BAY	NEAR OCEAN	altres
<1H OCEAN	1	0	0	0	0
INLAND	0	1	0	0	0
NEAR BAY	0	0	1	0	0
NEAR OCEAN	0	0	0	1	0
ISLAND	0	0	0	0	1

ocean_proximity, després de passar per **OneHotEncoder**: cinc columnes noves.

Per què no posar 0, 1, 2, 3? Perquè el model creuria que **NEAR BAY val el doble que INLAND**. Amb el one-hot, cada zona té la seva columna i el seu coeficient.

ISLAND només surt en **2 districtes** de l'entrenament. Una categoria tan rara no ensenya res: amb `min_frequency` va a parar a **altres**.

Resultat: l'error baixa de 51.217 $ a **50.102 $**. Una columna que no fèiem servir ja aporta informació.

Quan les categories tenen ordre, el número pot dir-lo

OrdinalEncoder amb l'ordre bo

Li passem l'ordre amb categories=[ORDRE]

```
Sense assalariats → 0
D'1 a 9 → 1
De 10 a 49 → 2
De 50 a 199 → 3
200 o més → 4
```

Una sola columna, i **més gran vol dir més assalariats**.

Sense dir-li l'ordre

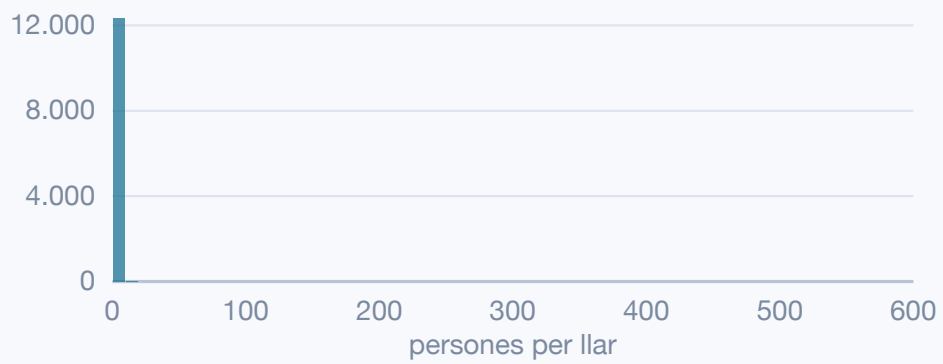
L'ordre que tria scikit-learn: l'alfabètic

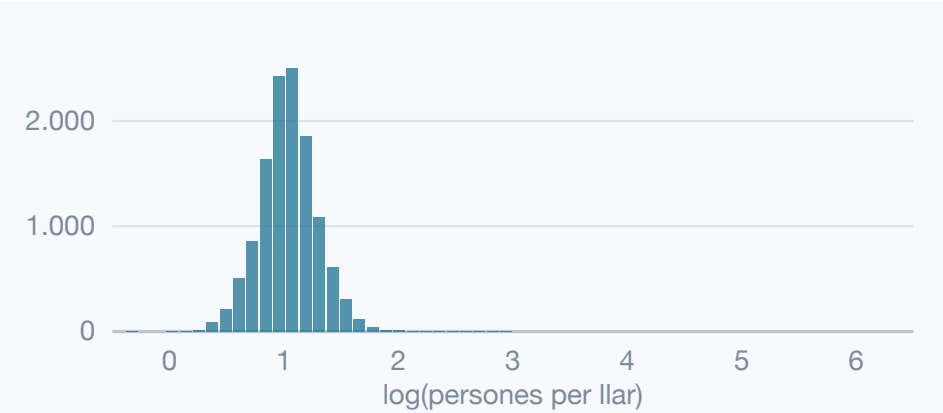
```
200 o més → 0
D'1 a 9 → 1
De 10 a 49 → 2
De 50 a 199 → 3
Sense assalariats → 4
```

L'empresa més gran queda **a baix de tot**, i les sense assalariats, a dalt.

Sense ordre (illa, sector, municipi), one-hot. Amb 67 municipis, **min_frequency** agrupa els petits: surten 32 columnes. Al final, 5 columnes de text es converteixen en 55 de números.

Proporcions i logaritmes: no tot ajuda, i per això es mesura





Persones per llar: gairebé tots els districtes entre 1 i 6, i uns quants fins a 600. El **logaritme** aixafa la cua i deixa una forma de campana.

Vuit variables (NB 2.2)	51.217 $
+ zona amb one-hot	50.102 $
totals → proporcions	51.676 $
proporcions amb logaritme	48.225 $

Les proporcions soles **empitjoren**: la cua llarga despista el model. Amb el logaritme, el millor resultat de la unitat.

Totes les variables a la mateixa escala

COEFICIENT DE…	SENSE ESCALAR	ESCALAT
median_income	41.119	**77.639**
latitude	–29.039	**–61.880**
housing_median_age	929	**11.711**
log_persones_per_llar	–95.053	**–25.622**

Error de validació, en tots dos casos: **48.225 $**.

StandardScaler deixa cada columna amb mitjana 0 i desviació 1. La regressió lineal **prediu exactament igual**.

Però els coeficients ja es poden comparar. Sense escalar, l'edat semblava no comptar gens (929) i log_persones semblava la més important. Escalats, la **renda** passa al davant i l'edat ja no és zero.

A la UT4, el k-NN mesura **distàncies** entre files, i allà escalar canvia les prediccions. També a la UT6.

fit() només amb l'entrenament. transform() amb tot.

APRÈN DE
Entrenament

`fit()` →

LA FÀBRICA GUARDA

```
les categories i l'ordre
la mediana de cada columna
la mitjana i la desviació
```

`transform()` →

- **Entrenament**
- **Validació**
- **Test segellat** (UT10)

Si la fàbrica es prepara amb la validació o el test, s'hi cola informació que el model no hauria de tenir: **fuga d'informació**, i l'error que mesurem surt massa bo.

Per això una categoria nova que apareix a la validació no trenca res: la fàbrica la tracta com a **altres**.

PER ENDUR-SE'N

Abans d'obrir el NB 3.1

1. Una **correlació** diu si dues variables pugen i baixen juntes, de –1 a 1. Mira-la abans d'entrenar.
2. Dues columnes molt correlacionades entre elles **diuen el mateix**. Una correlació baixa no vol dir inútil, i una d'alta **no vol dir causa**.
3. Si hi ha valors extrems, **Spearman** és més de fiar que Pearson. I sempre, el gràfic.
4. El model vol números: **one-hot o ordinal** per al text, **imputar** els buits, **logaritme** per a les cues llargues, **escalar** les escales.
5. Les fàbriques fan **fit() només amb l'entrenament**.