MP 5134 · UT4

Classificació: regressió logística i k-NN

Abans d'obrir els notebooks: com aprèn un model a decidir entre classes, i com es mesura si les seves decisions serveixen per a alguna cosa.

Pere Prohens · Politècnic Llevant · Curs 2026-27

ON SOM

Fins ara predèiem un número; ara, una categoria

Regressió

UT2 i UT3 · Quant val?

El preu d'un districte de Califòrnia. La resposta és una **quantitat**, i l'error es mesura en dòlars: quant ens hem desviat.

La recepta, l'entrenament i la prova, el model de referència i l'escalat ja els coneixes. Tot això continua valent.

Classificació

UT4 · 4 notebooks i una sessió de consolidació

La resposta és una **classe**. L'error ja no és «quant», sinó «m'he equivocat o no», i de quina manera.

`És un Adelie?` `Quina espècie és?`

`Plourà demà?` `Caurà pluja forta?`

Pingüins als NB 4.1 i 4.2 · AEMET de Palma als NB 4.3 i 4.4

1 · LA RECEPTA · NB 4.1

Cinc passos, els mateixos per a tots els classificadors

1 · PREPARAR

`X, y`

Triem les columnes i la resposta.

2 · PARTIR

`stratify=y`

Entrenament i prova, amb la mateixa proporció de cada classe.

3 · ENTRENAR

`fit`

Només amb les dades d'entrenament.

4 · COMPARAR

`Dummy`

Encerts del model contra els d'una referència que diu sempre el mateix.

5 · PREDIR

`predict`

Fem servir el model amb casos nous.

96,5%

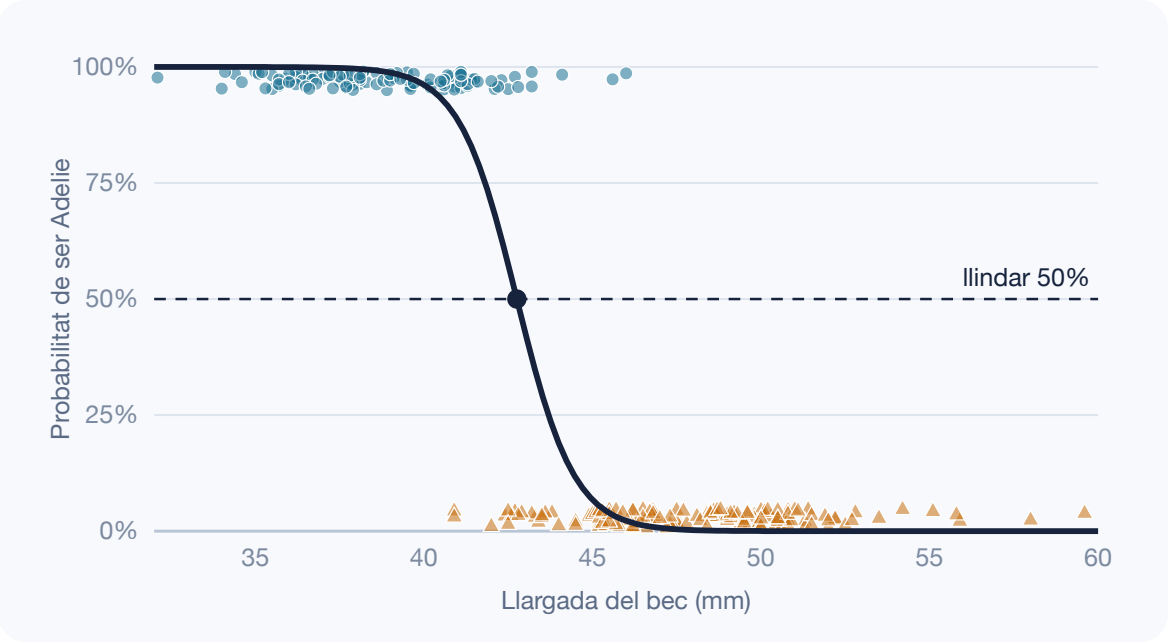
encerts del model: és un Adelie, mirant el bec?

55,8%

encerts de la referència, que diu sempre «no»

Sense la referència, un percentatge d'encerts **no diu res**. Aquí la diferència és clara: el model ha après.

El model no diu sí o no: calcula una probabilitat

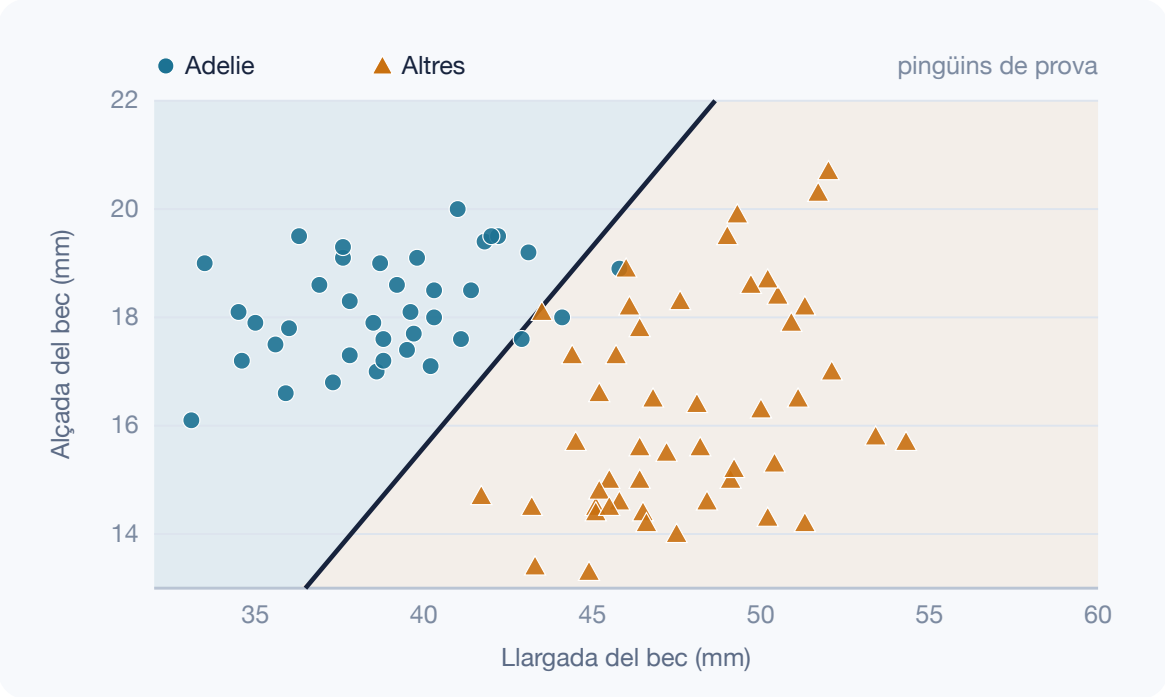


La **regressió logística**, malgrat el nom, classifica. La corba en forma de S converteix la mesura en una probabilitat entre 0 i 1. Per sobre del **llindar**, el model diu «SÍ».

BEC (MM)	PREDICT_PROBA	PREDICT
38 × 19	**100,0%**	Adelie
50 × 15	**0,0%**	no
42,5 × 18	**74,9%**	Adelie, amb dubtes

Tres pingüins nous, amb el model de la llargada i l'alçada del bec.

On es talla la probabilitat ho decidim nosaltres



La línia marca on la probabilitat val un 50%: és la **frontera de decisió**. Els punts que queden a la zona de l'altre color són errors. En una regressió logística, la frontera sempre és recta.

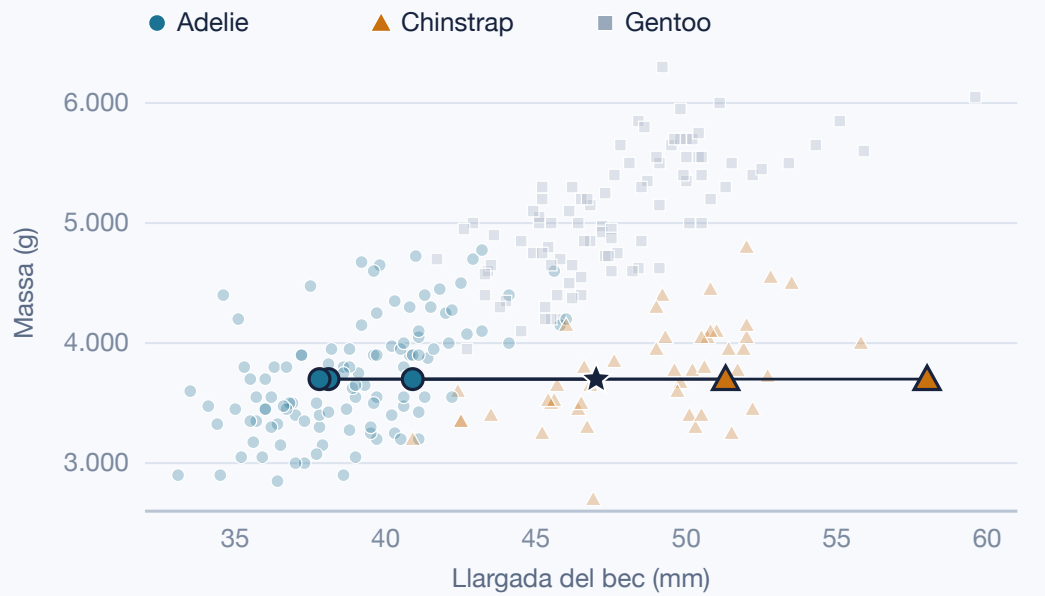
LLINDAR	MARCATS	FALSES ALARMES	ADELIE PERDUTS
20%	38	1	1
50%	35	0	3
95%	32	0	6

Llindar baix: se n'escapen menys, però hi ha més falses alarmes. Llindar alt: a l'inrevés. **Quin error ens surt més car?**

Digues-me amb qui vas i et diré qui ets

Sense escalar

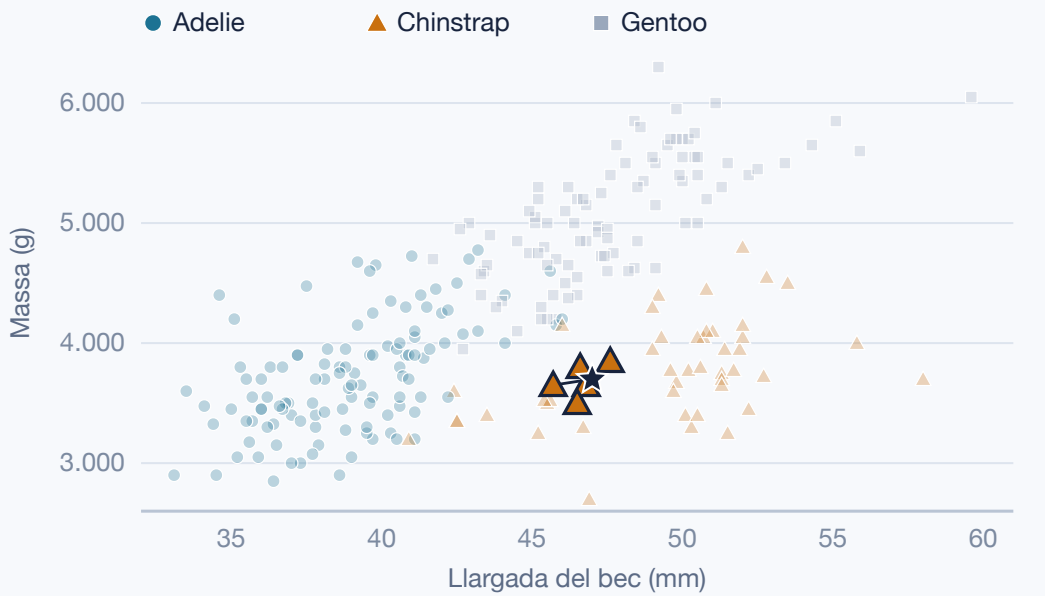
ENCERTS 79,1%



Els cinc veïns de l'estrella pesen 3.700 g, com ella, però el bec els va de 37,8 a 58 mm. **Un gram compta igual que un mil·límetre**, i la massa decideix tota sola. Vota Adelie.

Escalat

ENCERTS 95,3%



Amb **StandardScaler**, les dues mesures compten igual. Els cinc veïns s'hi assemblen de debò, i són cinc Chinstrap.

El k-NN no aprèn cap fórmula: guarda l'entrenament i fa votar els k casos més semblants. **Amb el k-NN, sempre s'escala**, també el cas nou.

La k: ni memoritzar ni aplanar-ho tot

`k=1`

Memoritza

entrenament 100% · prova 91,9%

Cada pingüí d'entrenament és el seu propi veí. Encerta tot el que ja ha vist, com el polinomi de grau alt del NB 2.3.

`k=5`

Entremig

entrenament 95,7% · prova 95,3%

Prou veïns perquè un pingüí estrany no decideixi sol, i prou pocs perquè cada espècie tingui veu.

`k=151`

Ho aplana tot

entrenament 75,8% · prova 76,7%

Vota més de la meitat de l'entrenament. Els Chinstrap, que només en són 51, no guanyen mai cap votació: **no en detecta cap**.

Al NB 4.2 provareu altres k i altres particions. A la UT7 aprendrem a triar-la amb mètode.

Dos classificadors, dues maneres de decidir

	REGRESSIÓ LOGÍSTICA	K-NN
Frontera	Feta de línies rectes	Tan torta com calgui
Escalar	Recomanable	**Imprescindible**
Entrenar	Més lent	Instantani: només guarda
Predir	Molt ràpid	Més lent com més dades
Explicar	Amb el signe dels coeficients	Amb els veïns que han votat

Els encerts no ho decideixen tot.

Una app que ha de respondre a l'instant amb milions de casos, o un comitè que vol entendre cada decisió, poden preferir models diferents amb el mateix percentatge d'encerts.

Plourà demà? Un 87% d'encerts que no diu res

87,2%
encerts del model, amb les nou mesures d'avui

87,0%
encerts de la referència, que diu sempre «no plourà»

A Palma, l'endemà plou un 13,1% dels dies. Dir que no és una aposta segura, i el percentatge d'encerts no ens deixa veure si el model ha après.

	DIU «NO»	DIU «PLOU»
NO PLOU	708 vertaders negatius	5 falses alarmes
PLOU	100 se'ns escapen	7 vertaders positius

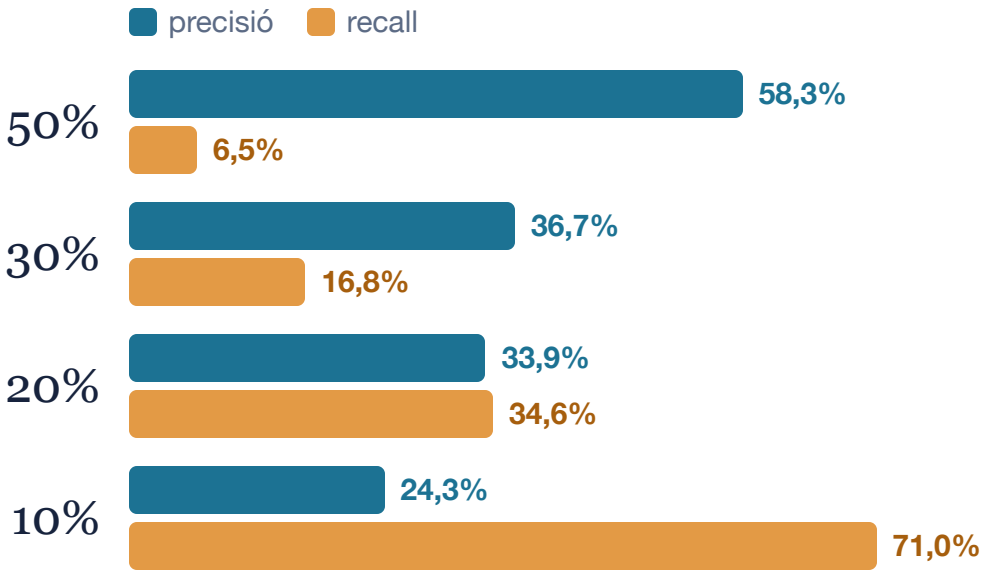
Files: el que ha passat. Columnes: el que diu el model. Dels **107** dies que va ploure, el model n'ha avisat **7**. «Positiu» vol dir la classe que busquem, no bona notícia.

Quatre preguntes a la matriu, quatre mètriques

MÈTRICA	PREGUNTA QUE RESPON	COMPTES	AQUÍ
Accuracy	Quin percentatge de dies encerta?	(708+7) de 820	**87,2%**
Precisió	Quan avisa de pluja, quantes vegades plou?	7 de 12	**58,3%**
Recall	Dels dies que plou, quants n'avisa?	7 de 107	**6,5%**
Specificity	Dels dies que no plou, quants n'encerta?	708 de 713	**99,3%**

Si n'heu de recordar dues: la **precisió** diu si les alarmes són de fiar, i el **recall**, si se n'escapen gaires. Aquest model, quan avisa, encerta més de la meitat de les vegades… però **quasi mai no avisa**.

Baixar el llindar: més pluges avisades, més falses alarmes



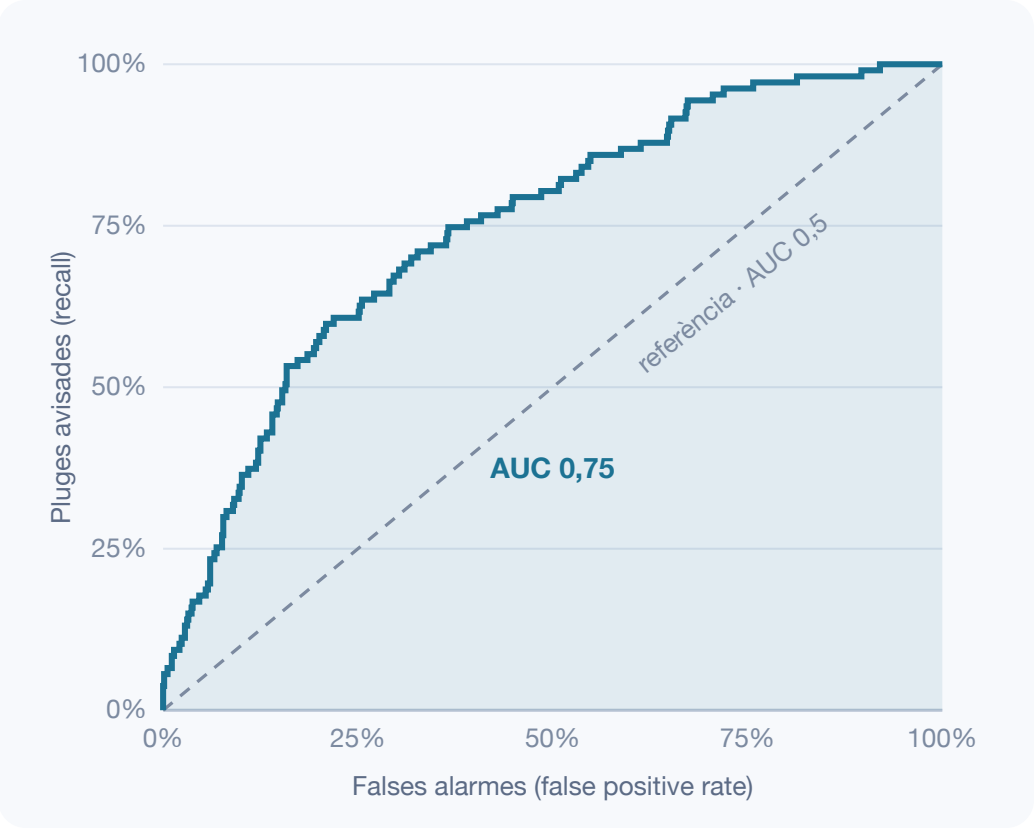
Llindar: la probabilitat a partir de la qual el model diu «plou».

Pujar el recall fa baixar la precisió, i a l'inrevés. No hi ha cap llindar que ho faci tot bé.

Qui no es pot permetre que se li escapi una pluja vol un llindar baix. Qui no vol molestar amb avisos equivocats, un d'alt.

El llindar el tria el client: abans de tocar-lo, cal saber qui farà servir el model i què li costa cada error.

Tots els llindars en un sol dibuix



Cada punt de la corba és un llindar. Com més amunt, més pluges avisades; com més a la dreta, més falses alarmes. Un model perfecte pujaria tot dret per l'esquerra. La referència, que no sap res, fa la diagonal.

L'**AUC** és l'àrea sota la corba: **0,5** és l'atzar i **1**, la perfecció. El nostre model fa **0,75**: ha après alguna cosa de debò, que el percentatge d'encerts no deixava veure.

Serveix per comparar models sense haver de triar abans el llindar.

Pluja forta: el model del 97% que no avisa mai

Regressió logística

ENCERTS 97,1%

	DIU «NO»	DIU «PLUJA FORTA»
NO	796 vertaders negatius	0 falses alarmes
PLUJA FORTA	24 se'ns escapen	0 vertaders positius

Igual que la referència: diu sempre «no». **No n'avisa cap.**

Amb class_weight="balanced"

ENCERTS 73,4%

	DIU «NO»	DIU «PLUJA FORTA»
NO	591 vertaders negatius	205 falses alarmes
PLUJA FORTA	13 se'ns escapen	11 vertaders positius

Avisa de **11 de 24**. Precisió del 5,1%: poca, però a l'atzar seria del 2,9%.

Més de 10 mm només cauen un 2,9% dels dies. `class_weight="balanced"` fa que, mentre entrena, cada dia de pluja forta pesi com uns 34 dels altres. Menys encerts, però **és l'únic dels dos que serveix**.

Cap mètrica no diu quin error surt més car

Fals positiu

Avisar quan no calia

Protecció Civil posa les brigades de guàrdia i no plou

Hores de feina perdudes. Si passa massa sovint, la gent deixa de fer cas dels avisos.

Fals negatiu

Callar quan calia avisar

Cau la pluja forta i no hi ha ningú de guàrdia

Torrents que surten de mare, carrers inundats, gent atrapada.

La mètrica no la tria el model: la tria el problema.

Al NB 4.4 ho debatreu amb altres casos: un cribratge mèdic, un detector de frau bancari, un filtre de correu brossa…

PER ENDUR-SE'N

Abans d'obrir el NB 4.1

1. Classificar és triar una classe, sempre amb la mateixa recepta: preparar, partir amb **stratify**, entrenar, **comparar amb la referència** i predir.
2. El model calcula una **probabilitat**. El **llindar** la converteix en una decisió, i el triem nosaltres.
3. El **k-NN** fa votar els veïns: sempre s'escala, i la k no ha de ser ni massa petita ni massa gran.
4. Quan una classe és rara, el percentatge d'encerts **enganya**: mira la matriu de confusió, la precisió i el recall.
5. Abans de mesurar, pregunta **quin error surt més car**.